

# Report of the Deep Learning for Natural Language Processing

ShihuiYang  
yangshihui@buaa.edu.cn

## 摘要 (Abstract)

词向量的建模作为自然语言处理的重要任务之一，其质量直接影响下游语义理解性能。本研究以金庸武侠小说《天龙八部》为特定领域语料，分别通过基于分布式表示的 Word2Vec 模型与基于深度学习的长短期记忆网络 (LSTM) 训练中文词向量，并使用构建相似度矩阵、词汇关系网络、聚类分析作为验证方法来验证词向量有效性，比较这两种模型在中文词向量构建中的差异表现。实验结果表明，Word2Vec 模型在非主线人物关系挖掘中展现出共现模式的局部敏感性，而 LSTM 模型通过长程依赖学习更精准地表征了核心人物间的复杂语义关系；两类模型在门派、人物与武功的语义区分上均存在局限性，但 Word2Vec 在人物与武功的聚类任务中表现更优，印证了分布式表示对局部语义特征的强捕捉能力。

## 引言 (Introduction)

词向量 (wordvectors) 是词嵌入 (wordembeddings) 生成的向量表示，通过特定模型 (如 Word2Vec、GloVe、LSTM) 将词语的语义和句法特征映射到低维连续的向量空间中，有助于机器学习算法更好地处理和分析文本数据。词向量有诸多应用场景，例如文本分类、情感分析和语义相似度计算等任务。作为经典的浅层神经网络模型，Word2Vec 通过上下文窗口内的词共现关系学习词向量表示。其核心假设是“分布语义假说” (DistributionalHypothesis)，即语义相似的词在相似上下文中出现。与传统神经网络不同，长短期记忆网络 (LongShort-TermMemory, LSTM) 通过门控机制 (输入门、遗忘门、输出门) 显式建模文本序列的长期依赖关系。通过引入自注意力机制，模型可强化关键实体的向量权重，缓解武侠文本中修饰性描写 (如招式细节) 带来的噪声干扰。本研究选择《天龙八部》作为核心语料，主要基于其语料规模、文本复杂性与文化代表性的双重考量。首先，该作品全书约 150 万字，保证训练数据量的同时能较好避免长尾噪声干扰；再者，此作品文本包含丰富的人名 (如“萧峰”“段誉”)、武功 (如“六脉神剑”“凌波微步”)、门派 (如“逍遥派”“青城派”) 和叙事段落，为验证词向量的细粒度语义关联性提供结构化测试场景。最后，《天龙八部》的武功命名中深厚的文化隐喻 (如“北冥神功”源自《庄子·逍遥游》)，为验证词向量对领域术语和文化符号的表征能力提供了理想样本。

## 方法论 (Methodology)

实验选用金庸武侠小说《天龙八部》全文作为语料库，分别使用 Word2Vec 模型和 LSTM 模型进行词向量建模，并通过计算人物相似度，制作人物关系网络，将人物、武功、门派类词汇进行聚类分析来验证训练后词向量的有效性。本实验的主要步骤如下：

### 第一步：数据预处理

该步骤主要包含两部分。第一部分是去除标点符号、停用词等无意义内容。第二部分是使用 `jieba.add_word` 将金庸武侠小说地名、人名、门派、武功、武器专有词汇添加到 `jieba` 分词词库中，避免错误分词。

### 第二步：模型构建与训练

**Word2Vec 模型：**使用 `gensim` 库实现 Word2Vec 模型，词向量维度设为 400 维，上下文窗口大小设为 15，最小词频设为 2，共训练 20 轮，采用 Skip-gram 模型。

**LSTM 模型：**使用 `tensorflow` 库实现 LSTM 模型，嵌入层维度设为 100 维，单层 LSTM 隐藏单元设为 128，使用 Keras 的 Attention 层，将 LSTM 输出和注意力输出拼接应用注意力机制，批次处理个数设为 64。

### 第三步：验证词向量有效性

**构建相似度矩阵：**总共构建两种相似度矩阵，第一种是提取最相关的 20 对人物相似度构建矩阵并用热力图进行可视化；第二种是选取 14 个天龙八部里的核心人物名字，分别通过余弦相似度计算其与其它核心人物的相似度构建相似度矩阵并用热力图进行可视化。



**绘制关系网络：**设置阈值为 0.02，提取相似度高于阈值的关系，突出显示重要人物，绘制人物关系网络图。

**进行聚类可视化：**获取人物、门派、武功类别词汇的词向量，合并所有向量后使用 t-SNE 进行降维。

## 实验与分析（ExperimentalStudies）

本文软件平台是 Windows10 操作系统，开发语言是 Python3.11 语言，开发所采用的基于 Python 语言的深度学习 Tensorflow2.15.1 框架和 Gensim4.3.0 进行本文的 LSTM 模型和 Word2Vec 的构建、训练与性能指标的计算，开发平台是 VisualStudioCode1.95.0。实验硬件平台是英特尔 i5-10400H CPU、16G 内存、RTX3050 显卡。

本实验结果包括：基于 Word2Vec 和 LSTM 模型最相关的 20 对人物相似度矩阵（图 1、图 2）、14 个《天龙八部》里的重要人物相似度矩阵（图 4、图 5）和人物关系网络（图 6、图 7）、词向量聚类分析图（图 8、图 9）。

[illegible]

“耶律洪基”这 14 个《天龙八部》里的重要人物构建相似度矩阵并绘制人物关系网络图，这 14 个人的词频如下：

| 人物   | 词频   |
|------|------|
| 段誉   | 3015 |
| 萧峰   | 1674 |
| 虚竹   | 1635 |
| 阿紫   | 1031 |
| 阿朱   | 929  |
| 王语嫣  | 864  |
| 段正淳  | 741  |
| 木婉清  | 739  |
| 钟灵   | 430  |
| 段延庆  | 301  |
| 李秋水  | 188  |
| 耶律洪基 | 175  |
| 无崖子  | 60   |
| 天山童姥 | 49   |

图 3：《天龙八部》核心人物词频统计表

如图 3 所示，《天龙八部》三个主角段誉（3015）、萧峰（1674）、虚竹（1635）的词频最高，词频较低的有耶律洪基（175）、无崖子（60）、天山童姥（49）。基于 Word2Vec 模型的核心人物关系相似度矩阵结果如图 4 所示：






图 4：基于 Word2Vec 模型的核心人物相似度矩阵

如图 4 所示，和“段誉”相似度最高的是其恋人兼堂妹钟灵（0.43），然后是恋人王语嫣（0.34）、交锋过的天山童姥（0.24）、父亲段延庆（0.22）和没有什么交集的无崖子（0.18），和“萧峰”相似度最高的是义兄耶律洪基（0.58），而不是他的结拜兄弟段誉、虚竹或一生挚爱阿紫，和“虚竹”相似度最高的是传授过给他武功三个师傅：李秋水（0.55）、无崖子（0.52）和天山童姥（0.52）。由此可见，本实验中 Word2Vec 模型训练出来的词向量在有一定的有效性，但精准度较低。




图 5：基于 LSTM 模型的核心人物相似度矩阵

由图 5 可很明显地观察到天龙八部的三个主角的最高相似度互为对方，如和“萧峰”相似度最高的是虚竹（0.82）和段誉（0.80），和“段誉”相似度最高的是虚竹（0.82）和萧峰（0.80），和“虚竹”相似度最高的是段誉（0.82）和萧峰（0.82），这一点很好地揭示了结拜三雄萧峰、段誉、虚竹的兄弟情。和“萧峰”相似度较高的依次还有其一生挚爱阿朱（0.76）和仇人段正淳（0.71）。

由此可见，相较于 Word2Vec 模型，LSTM 模型训练出来的词向量有效性较高。从模型结构的角分析，Word2Vec 和 LSTM 在训练词向量时表现出显著差异的原因主要源于其各自的架构特点和上下文捕捉能力。Word2Vec 作为一种基于局部上下文窗口的浅层神经网络模型，主要通过 Skip-gram 或 CBOW 架构学习词语的共现统计特征，其词向量的相似度计算更倾向于反映词语在局部语境中的共现频率，Word2Vec 对长距离语义依赖和复杂叙事结构的捕捉能力有限。相比之下，LSTM 作为一种具有门控机制的循环神经网络，能够通过长短期记忆单元建模文本序列中的长期依赖关系，其双向或多层结构进一步增强了上下文信息的整合能力，因此在图 5 中能够更准确地捕捉角色之间的深层叙事关联（如三主角的结义关系）和情感纽带（如萧峰与阿朱的爱情），这种优势可能源于 LSTM 对时序动态性和全局

语义特征的显式建模，使其在刻画复杂人物关系时表现出更高的语义敏感性和逻辑一致性。此外，LSTM 的序列建模特性使其能够更好地理解角色在完整叙事弧中的行为模式，而 Word2Vec 的静态词向量则难以区分同一角色在不同情节阶段的语义变化，这进一步解释了两种模型在人物关系相似度计算上的性能差异。




图 6: 基于 Word2Vec 模型的核心人物关系网络




图 7：基于 LSTM 模型的核心人物关系网络

图 7 表明，LSTM 模型有效地揭示了乔峰、段誉、虚竹等人物间的紧密联系，其网络结构的密集性反映了模型在识别和表达复杂人物关系网络中的高精度与敏感性。然而，其在表征相同人物间的互动时，网络图呈现出显著的稀疏性，表明其在捕捉如乔峰、段誉、虚竹间存在的紧密关系方面存在局限性。在《天龙八部》文本分析中，尽管天山童姥、李秋水和无崖子并非主要人物，但 Word2Vec 模型仍能有效识别并建立他们之间的联系，形成紧密的关系网络。相比之下，LSTM 模型在这一点上表现不足，未能充分揭示这三者间的相互关系。这一现象可从模型的原理结构中得到解释：Word2Vec 模型基于词向量共现原理，通过捕捉词汇在上下文中的共现模式，从而在向量空间中邻近表示语义相关的人物，使得即便是非主要人物的天山童姥、李秋水和无崖子也能在关系网络中得以紧密关联。而 LSTM 模型，由于其长短期记忆网络结构专注于序列数据的长期依赖性学习，可能在处理非主要人物间的较弱或间接联系时，受限于其时间序列信息的捕捉能力，导致无法像 Word2Vec 模型那样有效地构建出这些人物之间的关系网络。因此，Word2Vec 模型在揭示文本中非主要人物间复杂关系的能力上，展现出其独特的优势。




图 8：基于 Word2Vec 模型的人物、武功、门派类词向量聚类




图 9：基于 LSTM 模型的人物、武功、门派类词向量聚类

观察图 8、图 9 可发现两种模型在聚类表现上存在一定的局限性。具体而言，Word2Vec 和 LSTM 模型均未能有效区分门派与人物、门派与武功之间的语义关系，这种现象可能源于以下原因：首先，门派类别的样本数量相对较少，导致模型在训练过程中难以充分捕捉其语义特征；其次，门派作为一个抽象的组织概念，其语义可能与其他类别（如人物和武功）存在较强的关联性，从而增加了区分的难度。然而，Word2Vec 模型在区分人物与武功方面表现较为显著，能够形成相对明确的聚类区域，而 LSTM 模型在这一任务上的表现则相对较弱。此现象的原因可能是：在人物与武功的区分任务中，由于人物和武功通常在文本中具有明确的上下文边界和较强的局部语义特征，Word2Vec 能够有效地学习到这些词汇的独特表示，从而在降维可视化中形成相对明确的聚类区域。而 LSTM 模型的结构复杂，训练过程中容易受到过拟合或梯度消失等问题的影响，特别是在样本数量有限的情况下，这可能进一步降低其区分能力。在人物与武功的区分任务中，LSTM 生成的词向量可能包含了过多的全局语义信息，导致人物和武功的表示在向量空间中趋于混合，难以形成明确的聚类区域。

## 结论（Conclusion）

本研究通过 Word2Vec 和 LSTM 模型对《天龙八部》进行了语义相似度分析、关系网络构建及词向量聚类可视化。实验结果表明，两种模型在语义表征能力上呈现出显著的差异性，同时揭示了各自在不同任务中的优势与局限性。首先，Word2Vec 模型在非主要人物的关系挖掘中展现出独特优势。例如，天山童姥、李秋水和无崖子虽非故事主线人物，但其基于共现模式的向量表示成功捕捉了三者间的隐性关联，形成紧密的关系网络（图 6）。然而，该模型在主要人物关系的精准性上存在不足，如“萧峰”与义兄耶律洪基的相似度（0.58）高于其结拜兄弟段誉、虚竹或挚爱阿紫（图 4），这可能与模型对局部上下文依赖的过度敏感有关。相比之下，LSTM 模型通过长序列依赖学习，更有效地编码了主要人物间的深层语义关联。例如，三主角萧峰、段誉、虚竹的相似度互为最高（图 5），且其关系网络（图 7）



密集反映了结拜兄弟的情感纽带，同时阿朱（0.76）、段正淳（0.71）与萧峰的高相似度进一步验证了模型对复杂人物互动的敏感性。然而，LSTM 在处理非主要人物的弱关联时表现欠佳，如未能有效揭示天山童姥与李秋水、无崖子间的关系，这可能源于其对长程依赖的侧重与样本稀疏性的双重限制。

在词向量聚类任务中，两种模型均未能完全区分门派、人物与武功的语义类别（图 8、图 9）。Word2Vec 模型在人物与武功的聚类上表现相对明确，得益于其对局部上下文特征的强捕捉能力；而 LSTM 模型因全局语义信息的冗余混合，导致聚类边界模糊。这一现象反映了模型设计原理的本质差异：Word2Vec 的静态词向量更擅长固定语义的离散表征，而 LSTM 的动态序列建模则可能因过拟合或梯度问题弱化类别区分。此外，门派概念的抽象性及其与人物、武功的强关联性进一步加剧了聚类难度，尤其在样本量不足的情况下，模型难以提取独立的语义特征。

总体而言，本研究表明，Word2Vec 与 LSTM 模型在文学文本分析中具有互补性。Word2Vec 适用于挖掘非主线人物的隐性关联，而 LSTM 在捕捉主要人物间复杂关系上更具优势。未来的研究可尝试融合两种模型，或引入注意力机制以增强对弱关联的捕捉能力，同时通过扩充语料库与引入领域知识优化抽象概念的语义表征。此外，针对门派等复合语义单元的建模，需设计更细粒度的上下文标注策略，以提升模型在复杂文学分析中的综合性能。