

Report of the Deep Learning for Natural Language Processing

Shihui Yang
yangshihui@buaa.edu.cn

摘要 (Abstract)

文本生成作为自然语言处理的重要任务之一，在内容创作、人机对话、机器翻译等众多领域具有重要应用。本研究以金庸武侠小说《三十三剑客图》、《白马啸西风》、《越女剑》、《雪山飞狐》、《鸳鸯刀》为特定领域语料，分别通过 LSTM 与 Transformer 训练武侠小说风格文本生成模型，并通过定量和定性结合的三级评估体系（文本质量、生成多样性及武侠写作风格还原度），系统评估两类架构在武侠风格文本生成任务中的表现差异。实验结果表明，Transformer 架构文本生成模型整体表现显著优于 LSTM 架构，尤其在文本生成多样性和武侠写作风格还原度上展现出优越性。

引言 (Introduction)

文本生成技术历经数十年的生成范式演进，逐步实现了生成自然语言文本质量和生成速度的提升以及领域适应性的扩大。早期的文本生成方法依赖统计语言模型进行概率建模，此类方法基于单词级表示，难以捕捉词汇之间的相似性。如今，深度学习驱动的文本生成技术常采用基于编码器-解码器的序列到序列框架，通过端到端学习捕获深层次语义关联，实现生成质量的突破性提升。随后，文本生成技术的演进历经预训练语言模型（PLM）与大规模语言模型（LLM）两阶段范式跃迁。PLM 通过“预训练-微调”框架重构生成范式，显著降低领域适配成本并提升生成文本的语义连贯性。LLM 则通过参数规模（如 GPT-3/PaLM）与训练数据的双重扩展，验证了扩展法则下模型能力的相变效应，生成的文本在语法规范性、上下文一致性与领域泛化性层面实现质的跃升。

在文本生成领域中，长短期记忆网络（LSTM）与 Transformer 架构分别代表了序列建模的两种典型范式。本文以五部金庸武侠小说《三十三剑客图》、《白马啸西风》、《越女剑》、《雪山飞狐》、《鸳鸯刀》为核心训练数据，系统探究两种深度学习网络架构在武侠风格文本生成任务中的表现差异。武侠小说作为中国通俗小说的重要组成部分，凭借其独特的江湖叙事、侠义精神与武功体系构建了极具东方美学的文学世界。金庸先生作为武侠文学的集大成者，其作品通过精妙繁复的语言与浪漫叙事构造的侠谱，可为武侠小说风格的文本生成提供高质量语料库。LSTM 模型凭借其门控机制对时序信息的渐进式处理能力，在局部语境连贯性生成方面具有传统优势；而 Transformer 模型通过多头注意力机制对全局语义关系的动态建模，可能更契合武侠叙事中复杂人物互动与多线情节交织的特征。研究通过生成文本质量、生成多样性及武侠写作风格还原度这三方面维度，试图揭示不同模型架构对武侠文学特有要素（如打斗描写、侠客对话）的捕捉能力差异，以期为古典文学风格的数字化传

承与生成式人工智能的文化适应性研究提供实证参考。

方法论 (Methodology)

实验选用金庸武侠小说《三十三剑客图》、《白马啸西风》、《越女剑》、《雪山飞狐》、《鸳鸯刀》作为训练数据，共计 335,386 字。实验使用基于 LSTM 的序列到序列模型 (Sequence-to-Sequence Model) 和 Transformer 架构建立文本生成模型，输入种子文本，生成武侠风格文本，并计算生成文本困惑度、Dist-1 指标和人工定性评分，系统评估两类架构在文本质量、生成多样性、武侠写作风格还原度方面的性能差异 (研究曾尝试将小说文本摘要作 Transformer 的输入，把小说的全部内容作为 Transformer 的输出，建立 Transformer 架构进行训练，可能由于数据量过小生成结果十分不理想，故调整成了现有思路)。本实验的主要步骤为：数据预处理、词向量训练、模型构建与训练、生成文本并评估。

第一步：数据预处理

为学习原始文本的句法特征和符号使用，本实验采用最小化处理策略：保留所有标点符号和停用词、剔除非小说内容 (如剔除“本书来自 www.cr173.com 免费 txt 小说下载站”等广告文本。)、分词 (LSTM 分支使用 jieba 分词，Transformer 分支直接调用 bert-base-chinese 自带的 WordPiece 分词器。)

第二步：词向量建模

LSTM/Seq2Seq 分支：基于 FastText 训练静态词向量，词向量维度设为 100，上下文窗口跨度设为 3，最小词频过滤设为 5，并行计算线程数设为 4。

Transformer 分支：使用 bert-base-chinese 动态词向量模型，预训练词表容量为 21128，隐层表征维度设为 768，编码器堆叠层数设为 12，多头注意力并行计算头数设为 12，前馈网络隐层维度设为 3072，绝对位置编码最大长度设为 512，启用自回归生成模式。

第三步：文本生成模型构建与训练

LSTM/Seq2Seq：使用 tensorflow 库实现 LSTM 模型，嵌入层维度为 300，单层 LSTM 隐藏单元为 256，共训练 100 轮。

Transformer：解码器采用 top-p 采样，词表容量固定为 21,128 以保持与 bert-base-chinese 预训练权重的严格兼容；隐层维度设定为 768；设置 12 层 Transformer 隐藏层的堆叠，每层配备 12 个并行注意力头；前馈神经网络隐层维度扩展至 3,072 (缩放因子×4)；最大位置编码长度限定为 512，窗口尺寸 1,024，步长 256，共训练 200 轮。

第四步：生成文本并评估

文本质量：计算生成文本困惑度 (Perplexity, PPL) 来衡量句子中词语或分句的顺序合理性程度，PPL 值越低，表示该文本的语法越正确；人工检验文本的通顺、连贯程度。

生成多样性：采用 Dist-1 指标结合人工评估文本生成多样性。Dist-n 通过计算非重复 n-gram 与总词汇量之比衡量语句内部多样性，其数值与多样性呈正相关。

武侠写作风格还原度：人工对武侠小说风格的还原程度进行打分，评估要点包括武侠元素丰富度、文白比例协调性、叙事节奏把控度，满分为 10 分。

实验与分析 (Experimental Studies)

本文软件平台是 Windows10 操作系统，开发语言是 Python3.11 语言，开发所采用的基

于 Python 语言的深度学习 Tensorflow2.15.1 框架和 Gensim4.3.0 进行本文的 LSTM 模型和 Word2Vec 的构建、训练与性能指标的计算，开发平台是 VisualStudioCode1.95.0。实验硬件平台是英特尔 i5-10400H CPU、16G 内存、RTX3050 显卡。

实验给模型制定的任务为：将种子文本（“曾小贤吃过了烤鱼，”，“胡霏回眸一笑，”，“陆展堂大喝一声，”，“林瑛宛转身，”，“吕峰把碗筷一摔，”）作为输入序列，据此生成武侠风格文本。表 1、表 2 为两种架构生成的文本各指标评估结果（结果保留 3 位小数），表 3、表 4 为两种架构生成的文本。

表 1LSTM（Seq2Seq）架构生成的文本评估结果

文本序号	PPL	Dist-1	武侠风格还原度
L001	179.847	0.516	2.2
L002	76.239	0.534	3.5
L003	121.868	0.639	4.0
L004	101.119	0.541	2.7
L005	253.818	0.539	3.4

表 2Transformer 架构生成的文本评估结果

文本序号	PPL	Dist-1	武侠风格还原度
T001	178.112	0.656	6.6
T002	140.670	0.549	6.3
T003	209.181	0.644	7.1
T004	169.397	0.595	7.3
T005	170.502	0.549	5.5

现根据各级指标对评估结果进行分析：

在文本质量层面，LSTM 架构生成的文本语法较为正确，Transformer 架构表现较稳定。LSTM 架构生成文本困惑度范围为 76.239 至 253.818，平均值约为 146.578，而 Transformer 架构文本困惑度范围为 140.670 至 209.181，平均值约为 173.572。由此可见，LSTM 生成的文本质量波动较大，整体表现不稳定，可能与模型过拟合有关，Transformer 生成文本稳定性更好，但语法错误较多，可能因为生成的文本长度较长（约为另一种架构的三四倍）。

在生成文本多样性层面，Transformer 架构在生成文本的多样性方面表现优于 LSTM 架构。LSTM 架构生成文本 Dist-1 范围为 0.516 至 0.639，整体较低，说明生成文本的词汇多样性一般。Transformer 架构生成文本 Dist-1 范围为 0.549 至 0.656，整体较高，说明生成文本的词汇多样性较好。

在武侠风格还原度层面，Transformer 架构显著优于 LSTM 架构。LSTM 架构生成文本得分范围为 2.2 至 4.0，平均值约为 3.18，表明生成文本在武侠风格的还原上表现较差。Transformer 架构生成文本得分范围为 5.5 至 7.1，平均值约为 6.38，表明生成文本在武侠风格的还原上表现较好。

在人工综合评估时发现，两种架构生成的文本都较不通顺，Transformer 架构生成的文本虽然在武侠小说风格的还原上表现优异，将武侠对话场景（文本 T003）和武侠打斗场景（文本 T004）描写得较为丰富还原，但语句却较不通顺且缺乏逻辑性。此外，LSTM 架构生成的文本还出现标点符号使用严重错误（如换行符等）的现象，这可能是因为模型对特殊符号的敏感性不足或者超参数设置不当。

表 3LSTM 架构生成的文本

文本序号	种子文本	生成文本
L001	曾小贤吃过了烤鱼，	曾小贤吃过了烤鱼，但说，却是，。」 周威信一见，定将他，在地下，，了，那。我不杀他皇上我，你便了。」袁冠南道：「，连你了，了，！」忙，一惊，伸手向那凶徒的，而至。周威信手指一，得。逍遥子道：「两位，你要好心，我给我
L002	胡霏回眸一笑，	胡霏回眸一笑，便如，。 萧半和奔出，但伸手周威信将他叫道：「贼小子，你，你江湖上人称江湖人称『鸳鸯刀』？」盖一鸣道：「，你就抢给你？」林玉龙道：「我知道吧，把说的，解开，当真这麼？」盖一鸣道：「安，便问了。」盖一鸣道：「大哥料事如神，言之有理。」那少女道：「我不用，你给你
L003	陆展堂大喝一声，	陆展堂大喝一声，向这对宝刀却夫人，眼见四位将皇帝。」众是盖一鸣道：「不错，你到底这，不睡？」袁萧二人胸口，眼见林玉龙，也他。四人伸手道：「大人……」只听他仍是的人，瞧了，那少女身前，忙抱去。 盖一鸣道：「这麼容易，原来是你不知，不能不是他，在下的夫妻刀法。」花剑影
L004	林瑛宛转身，	林瑛宛转身，是，可还不能也，。」说著，说道：「人间姑娘，你还能给我，好朋友们？」常长风道：「打架，我来我伤了你夫妻，假。」林玉龙道：「，让你们什麼？」盖一鸣道：「我跟我们老人家一口。」说著他，伸手。卓天雄卓天雄又，骂道：「贼婆娘，。」那书生道：
L005	吕峰把碗筷一摔，	吕峰把碗筷一摔，，，原来他，，嘴里，，的，。 那少女道：「你这麼？」萧中慧道：「大哥料事如神，言之有理。」 卓天雄纵声好笑，道：「萧大侠是谁？」便便如，在人影上头顶动，已给逍遥子的一声。 萧中慧以，。卓天雄，飞出，自，，，侍卫，刀。那

表 4Transformer 架构生成的文本

文本序号	种子文本	生成文本
T001	曾小贤吃过了烤鱼，	曾小贤吃过了烤鱼，名镖队、慷慨重太岳四侠行侠虽然在江湖上的接过去，说道：「你放我嫁了吧！」四侠一听到门外，终于强行侠却知说道：「你出来，可猜到了孩子，我妈和我」那汉子双腿一碗热奶酪，武功全失望著他」那少妇与旁边满脸一颗铁念珠激飞而出招数十七八名卫大风大门之极，但心，喝道蓝焰冲天相邀。那少女抱著听得他们有什麼仇怨？难得意洋洋的向那书生平到自己落入怀，说著那婴儿的教人横眼一刀。苗若兰道：「是不得罪，就会满洲武功，我姓胡子，又好汉子，是已打定知道你的性命，要搭就没有人怪。」说道：「是客气！」张望著便一出口，只剩下过来仰慕他幽幽的事物，对方共有二人无雪地。他和我一言语，心中正没好，只看了得无敌人盗拼斗一场，微微一黑石围子，落在他的一根是黑的鼻子又是啊。始终於天下的得到杜希孟。突然之间，几步，拔拳打了穴的男仆，似乎给我爹怎麼说得两名。胡大爷走过来，馥裕，竟不堪，各位叔叔，早已晕倒在不同，足智多好人之理。
T002	胡 霏 回 眸 一 笑，	胡霏回眸一笑，阿四道：「他」永远捧起眉而来。苗若兰道：「你爹，你杀了我要你一曲折断了。」胡斐道：「我还有甚麽？苗大侠却没听爹说不许多了。苗若兰道：「你活了我不错，我。你爹爹说？我就知道我活了。」胡斐道：「他虽令你不敢说我一生一刀以此，便让我瞧会弯，到山里，但见她满了那跌打遍，再无敌人，良久，受人害了良久，又有什麼？」右手托上一红，一眼，道：「别说，片刻间短，思什麼古怪来到山峰上一下击去了。」众人齐却是苗若兰道：「我爹爹说八人，不得引他活过来。若兰不便是他下去。」胡斐道：「不是远远不敢瞧他。只觉重，还不能慢了我跟令尊比武之时，他快到片刻，他是他，但客人，站在凳上重重一闪身。我妈的。」胡一个软，铁锈，侧，雪地里，似有甚麽仇怨，伸手到被下一摸」
T003	陆展堂大喝一声，	陆展堂大喝一声，马，戒刀身子这时竟是扭打掉了。那几下憋了几句话，兀自己苍白虹捷，不久喝道：「各位姑娘子抱回来！」「喂，一刀拦住我刀拦在此，就打你看我叫，等丑事说不敢动静。」「大门周威信，呼：「久，把这位姑娘没见我我不等这里许，後破绽，就说？」周威信镖局一挟，抬腿将刀剑之意不出去横了进去，剑。那长剑鞘断为数日却早晨追赶去，竟然间，双眼见这时候从头一齐捧起，直在周威信虎口破裂，全家上有何况听田青文叫道：「嘿，恕小夥子在这里等我怎舍不知。」刘元鹤向陶子安。周威信身形一树出暗运内气，待毙命毒龙像妻子安抢上，喝道：「啊？」众人显是我也不饮马川道：「蠢丫头，待防，我怎能信他这一双刀抱著你打，拼命人五尺许多汉子要穴，不好身上，大像汉子的刀真枪战三百回来。」当真是镖队後，只一起身来。周威信从未见他砍死在坑中。陶子安听得出其不免就多少，靠向阮士中身畔。那左臂已被中上上下下，只听一道：「哈，我们两个什麼宝刀，私心想：「不错，我天

		龙门锄强扶弱，咱三娘子」
T004	林瑛宛转身，	林瑛宛转身，斥道。你孩子吧，你们吧埋私生满身避开突然叫什麼？」当即挥刀斜眼前，右手一堵住了一撞开左手从衣袖堂侍卫士突然间倏忽听得意，端些叫道：「我穴道我！」说著自己看，已将你懂得什麼还是回事。大怒气将右手腿，乱动，六七人说：「弟子，岂不用我给你是谁？」萧中慧心中慧道：「你们既是夫妻打不用这谁？」说著双手下去。那孩子，伸手去探她鼻息。一声，与曹云奇只见他的一扬，大怒吼，叮叮一套呢，转眼见那白衣衫人纵马腹。曹云奇恨恨的头发足疾奔，竟向他横当下了一使了一把抓住倒退著手腕。袁冠男子一怔，将插在地，冷笑，叫道：「这批人的汉子，自己身子在车尔库身幌动手来。」提起身来，轻轻在马腹之下，萧府上了点头，已扑面打在马鞍头盖了下去。向前一拿著他稍有何能够持大叫道：「好啦。」，眼中慧的甚麽也没瞧见了片刻，抢先钉中她的那女子上有何灾难，但这麽一吓了一跳，就此伤她头顶，不动，眼见那女孩子。向张镖师和詹镖师父学的声，当下奋起平生之形，手可撒娇，似乎是真正的马腹上点头，左懂的话，他的帐篷之下，见青文的那长风。
T005	吕峰把碗筷一摔，	吕峰把碗筷一摔，江湖上哭了数寸，说道：「罢了。」苏鲁克、车尔库和苏普依计老人收起来，软倒在她面上了一阵，和阿曼同时，说道：「阿曼在这里来不过得很可惜！」苏鲁克「呸」的头发上堆积起一个女子尖声如果见她并肩住了。他又惊又走进大声。苏鲁克和车尔库所偷袭的，直想：「不错，倒足了干甚麽？」苏普在腰间听得苏普长声，四手中了，终能追上钉。车尔库伸手挽住了骆驼，眼之间，任飞燕被高台，就在车尔库立时，落在雪地里，两人逃去啦。这时候了。计老人粗重的伤痕。骆驼和车尔库摇摇幌幌的身后。两人来，便抛死的角斗。苏普身子，车尔库和阿曼的背上一个银狐垫子上撞在一阵，摔下重赏，跟他一世，就算是跟著「只要我在跟你立时便到底是那里去？」苏鲁克人的隐隐作疼起来。殿堂上来，每一句话说话，说道：「师父亲的。」陈达海大怒气，同在她左手去拉齐的。李文秀只淡淡的块手帕是苏普紧紧搂著阿曼，背心中指一股急忙回家，她听到他相会给我叫道：「你儿子。」苏鲁克抢上面子，从山峰，还有谁敢再逗留？」苏普和阿曼说道：「汉人追踪那里，你另外还有些吗？」他说去瞧满地图，接著，道：「他说这是拿，我

结论（Conclusion）

在文本生成任务中，LSTM 和 Transformer 两种架构在不同层面的表现各有优劣。从文本质量层面来看，LSTM 生成的文本困惑度范围较大，波动性较强，整体生成质量不够稳定，这可能与模型过拟合有关。相比之下，Transformer 架构生成的文本在困惑度上表现较为稳定，夹杂许多文言元素，但语句不通顺且缺乏逻辑性，这可能是因为没有处理金庸小说中的

文言元素，如对金庸小说中的文言词汇和表达方式进行特殊的标注或替换，使其更易于模型理解和学习。在生成文本的多样性方面，Transformer 表现优于 LSTM，尤其表现在词汇多样性上。在武侠风格还原度层面，Transformer 显著优于 LSTM。Transformer 生成的文本在武侠对话场景和打斗场景的描写上较为丰富，较为符合金庸武侠小说的风格，而 LSTM 生成的文本在武侠风格的还原上表现较差。此外，人工综合评估发现，两种架构生成的文本在语句通顺性和逻辑性上均存在不足，尤其是 Transformer 生成的文本尽管在武侠风格的还原上表现优异，但语句不通顺且缺乏逻辑性。LSTM 生成的文本还出现了换行混乱的现象，这可能源于模型对特殊符号的敏感性不足或超参数设置不当。

综上所述，相较于 LSTM 模型，基于 Transformer 架构的模型在文本生成任务中展现出更为显著的优势，尤其是在武侠风格的深度还原和生成文本的词汇多样性方面表现突出。然而，两种模型在生成文本的语句通顺性和逻辑连贯性方面仍存在一定局限性，需要进一步优化和改进。

本次研究尚存在诸多不足之处：首先，用于模型训练的语料规模较小，限制了模型的学习能力和生成效果；其次，未能对训练语料中的文言元素进行预处理，导致模型在学习金庸小说特有的语言风格时面临较大挑战；此外，模型参数设置不够合理，且训练策略有待进一步优化。这些因素都对实验结果产生了一定影响。未来的研究可以从以下几个方面展开：其一，进一步扩大训练数据规模，丰富语料来源，尤其是增加高质量的武侠小说文本；其二，对模型架构进行改进，探索更适合武侠小说生成任务的模型结构；其三，优化生成策略，提升文本生成的流畅度和逻辑性；其四，可以尝试对比直接训练某种文学风格文本与预训练+风格迁移路径的模型性能差异，从而为模型选择和训练策略提供更有针对性的参考。通过这些探索，有望进一步提升模型的生成能力和文本质量。